**Universidad Autónoma de Chihuahua**

**Facultad de Ingeniería**

DOCUMENTO DE ESPECIFICACIÓN DE PRODUCTO (PRD)

PROPUESTA DE PROYECTO DE SERVICIO SOCIAL

# Plataforma Predictiva de Severidad de Siniestros Viales

## mediante Machine Learning y Datos Geoespaciales

**Autor:** Nicolás Paúl Nevárez Loera
**Carrera:** Licenciatura en Ingeniería en Ciencias de la Computación
**Periodo:** 2 de septiembre de 2026 – 28 de febrero de 2027

Chihuahua, Chih.

# Índice


**1. I. Resumen Ejecutivo** **2**

**2. II. Contexto, Diagnóstico y Justificación** **2**
2.1. El problema de la estadística reactiva . . . . . 2
2.2. Justificación del enfoque metodológico . . . . . 2

**3. III. Visión del Proyecto y Experiencia de Usuario (UX)** **2**

**4. IV. Actores y Roles** **3**

**5. V. Flujos Clave de Procesamiento (Metodología KDD)** **3**

**6. VI. Requerimientos del Sistema** **3**
6.1. Requerimientos Funcionales (RF) . . . . . 4
6.2. Requerimientos No Funcionales (RNF) . . . . . 4

**7. VII. Arquitectura de Hardware y Software** **4**
7.1. 1. Entorno de Desarrollo y Entrenamiento (Proporcionado por el alumno) . . . . 4
7.2. 2. Entorno de Despliegue Institucional (Hardware Requerido) . . . . . 4
7.3. 3. Stack de Software . . . . . 5

**8. VIII. Hoja de Ruta Detallada** **5**

**9. IX. Gestión de Riesgos y Mitigaciones** **5**

**10. X. Criterios de Éxito y Métricas** **5**

# I. Resumen Ejecutivo

La ciudad de Chihuahua produce un volumen considerable de datos relacionados con la movilidad y la siniestralidad vial. Sin embargo, este activo de información rara vez trasciende el nivel de la estadística descriptiva reactiva para convertirse en una herramienta de prevención basada en evidencia.

El presente proyecto propone cerrar esa brecha mediante el diseño, desarrollo y validación de un **pipeline de Machine Learning estructurado**, capaz de predecir la severidad probable de un siniestro de tránsito (Solo Daños Materiales, No Fatal y Fatal) a partir de la combinación de tres fuentes de datos heterogéneas:

1. El historial oficial de accidentes viales (SIGMUN).
2. La proximidad de unidades económicas de riesgo (DENUE, vía SIGMUN).
3. Las condiciones climáticas exactas (Open-Meteo API).

El resultado final será una **Aplicación Web (Dashboard) interactiva** que permitirá al cuerpo vial y a planificadores urbanos consultar el riesgo de la ciudad en tiempo real o mediante pronósticos futuros, dotándolos de una herramienta predictiva, visual e intuitiva para la prevención de fatalidades.

# II. Contexto, Diagnóstico y Justificación

## El problema de la estadística reactiva

Actualmente, los cuerpos viales operan bajo esquemas empíricos y análisis reactivos (ej. mapas de calor anuales). Esto ignora que un accidente es la intersección de tres dimensiones variables:

- **Infraestructura y entorno:** Geometría urbana y presencia de locales de riesgo.
- **Condición temporal y ambiental:** Hora, día de la semana y clima.
- **Actividad humana:** Concentración en zonas de vida nocturna o corredores comerciales.

Al carecer de un cruce automatizado de estas dimensiones, es imposible anticipar el riesgo.

## Justificación del enfoque metodológico

Se opta por un aprendizaje supervisado multiclase (Random Forest / XGBoost). Para que el sistema sea viable en la vida real, se integra la API de **Open-Meteo**, la cual permite un enfoque dual: proveer datos históricos para entrenar el modelo, y proveer pronósticos meteorológicos reales para las predicciones de los próximos días, eliminando la necesidad de que el usuario adivine el clima.

# III. Visión del Proyecto y Experiencia de Usuario (UX)

El sistema final no será un script complejo, sino un **Dashboard Web** (desarrollado con Streamlit) diseñado para operadores no técnicos. La experiencia de uso se define en tres ejes:

- **El "Aquí y Ahora":** Al abrir la aplicación, el sistema consulta la hora actual y el clima en tiempo real, mostrando inmediatamente un "Velocímetro de Riesgo" para el estado actual de la ciudad.

- **Simulación Inteligente (Smart Calendar):** El usuario puede seleccionar un sector y una fecha futura. Si la fecha corresponde a los próximos 6 días, el backend consulta automáticamente el pronóstico meteorológico (Forecast API); si es a largo plazo, utiliza medias probabilísticas.
- **Sectorización y Mapeo Interactivo:** En lugar de buscar calles manualmente, la ciudad estará dividida por macro-sectores (Norte, Centro, Sur, etc.). El sistema renderizará un mapa interactivo (Folium) destacando la zona y las unidades DENUE que aumentan el peligro.
- **Interpretabilidad (Los Por qués):** Mediante algoritmos SHAP (SHapley Additive exPlanations), el sistema traducirá la matemática a lenguaje natural, indicando exactamente qué factores elevaron el riesgo (ej. "El riesgo subió un 40 % por presencia de lluvia y 15 % por densidad de bares").

## IV. Actores y Roles

- **Desarrollador (Alumno):** Responsable técnico integral. Ejecutará el diseño del ETL, el *Feature Engineering*, el entrenamiento, la integración con APIs y el desarrollo del frontend en Streamlit.
- **Usuario Final (Comandante / Analista Vial):** Operador del dashboard. Utilizará los velocímetros de riesgo y los mapas interactivos para planificar patrullajes, retenes de alcoholimetría u operativos de reducción de velocidad sin necesidad de conocer la lógica de código subyacente.

## V. Flujos Clave de Procesamiento (Metodología KDD)

1. **Ingesta Geométrica y Tabular:** Validación de geometrías y limpieza de atípicos.
2. **Enriquecimiento Espacial:** Uso de GeoPandas para calcular áreas de influencia (*buffers*) entre sectores de accidentes y polígonos DENUE, generando variables de densidad de riesgo.
3. **Enriquecimiento Temporal (Enrutador de API):** Script lógico que determina si la fecha solicitada requiere una consulta a la base de datos histórica o al pronóstico meteorológico de Open-Meteo.
4. **Entrenamiento y Evaluación:** Balanceo de la clase fatal con SMOTE y optimización de hiperparámetros.

## VI. Requerimientos del Sistema

### Requerimientos Funcionales (RF)

| ID | Descripción |
|---|---|
| **RF01** | Fusionar datos de SIGMUN, DENUE y Open-Meteo mediante *Spatial Joins*. |
| **RF02** | Producir una predicción multiclase con representación visual (Velocímetro). |
| **RF03** | Automatizar la entrada climática según la fecha seleccionada en el calendario web. |
| **RF04** | Generar texto explicativo (SHAP) sobre los factores que determinan el nivel de riesgo. |

### Requerimientos No Funcionales (RNF)

| ID | Descripción |
|---|---|
| **RNF01** | Mantener un F1-Score ponderado >75 %, priorizando minimizar falsos negativos fatales. |
| **RNF02** | La interfaz web debe responder a simulaciones de predicción en menos de 2 segundos. |
| **RNF03** | Interfaz gráfica intuitiva, operable con un manual básico sin conocimientos de IA. |

## VII. Arquitectura de Hardware y Software

### 1. Entorno de Desarrollo y Entrenamiento (Proporcionado por el alumno)

El procesamiento de tensores, limpieza de datos geoespaciales y entrenamiento del modelo requieren alto poder de cómputo, el cual se ejecutará en la estación de trabajo del alumno:

- **CPU / RAM:** AMD Ryzen 7 5700G y 32 GB RAM (garantizando el procesamiento de DataFrames masivos en memoria durante las operaciones de *spatial join*).
- **GPU y Display:** ASUS RX 6600 conectada por DisplayPort para visualización cartográfica sin latencia. Entorno secundario de pruebas en macOS.

### 2. Entorno de Despliegue Institucional (Hardware Requerido)

Para que el Dashboard Web opere de manera ininterrumpida (24/7) y pueda ser consultado en cualquier momento por el cuerpo de policía vial o analistas, **se requiere la asignación de un recurso de hardware** (ej. una Mini PC, servidor local o máquina virtual).

- **Especificaciones mínimas sugeridas:** Procesador de 4 núcleos (Intel Core i5 / Ryzen 5), 16 GB de RAM, 256 GB SSD, conexión a red o internet para el consumo de la API de Open-Meteo.
- **Uso:** Alojamiento del contenedor Docker con la aplicación Streamlit y el modelo serializado.

### 3. Stack de Software

- **Procesamiento:** Python 3.10+, Pandas, GeoPandas, Shapely.
- **Machine Learning:** Scikit-Learn, XGBoost, imbalanced-learn (SMOTE), SHAP.
- **Frontend y Visualización:** Streamlit, Folium (Mapas interactivos).

## VIII. Hoja de Ruta Detallada

| Periodo | Fase y Objetivos |
|---|---|
| **02 Sep - 30 Sep** | **Fase 1: Ingesta.** Carga de GeoJSON (SIGMUN) y DENUE. Homologación sectorial. |
| **01 Oct - 31 Oct** | **Fase 2: Feature Engineering Cruzado.** Conexión a Open-Meteo. Spatial Joins con locales. |
| **01 Nov - 15 Dic** | **Fase 3: Entrenamiento Base.** Aplicación de SMOTE y algoritmos de ensamble. |
| **16 Dic - 31 Ene** | **Fase 4: Tuning.** Uso de GridSearchCV. Integración de interpretabilidad SHAP. |
| **01 Feb - 28 Feb** | **Fase 5: Despliegue Frontend.** Creación del Dashboard Web (Streamlit), renderizado del mapa (Folium) y entrega técnica. |

## IX. Gestión de Riesgos y Mitigaciones

| Riesgo | Impacto | Estrategia de Mitigación |
|---|---|---|
| **Overfitting** | Alto | Aplicación rigurosa de K-Fold Cross-Validation. |
| **Desbalance severo** | Alto | Uso de SMOTE solo en entrenamiento. Monitoreo del Recall por clase. |
| **Errores GeoJSON** | Medio | Reparación topológica previa mediante Shapely (`buffer(0)`). |
| **Fallas en API Externa** | Medio | Manejo de excepciones en Python con respuestas climáticas por defecto (medias históricas) si Open-Meteo experimenta caídas. |

## X. Criterios de Éxito y Métricas

- **Métrica de Modelo:** F1-Score Ponderado >75 % y maximización de Recall en siniestros fatales.
- **Métrica de Usabilidad:** El Dashboard despliega resultados y mapas en menos de 2 segundos.
- **Entregable Final:** Sistema operando en el hardware asignado y código fuente documentado.